

# Balanced Datasets Are Not Enough- Estimating and Mitigating Gender Bias in Deep Image Representations (ICCV 2019)

---

Undergraduate Researcher at CVLab

Lee Dohyeong

2025.8.14

# Contents

---

- Introduction
- Method
- Experiments
- Conclusion

# Introduction

---

- Problem :

- Blanced Data(예 : 남자,여자 1:1) -> Fair [직관적]
- Blanced Data -> model-> gender bias [현실]

- 라벨이 없는 (유추) 단서 : 아이동반여부, 헤어스타일 등
- 예시 : Cooking과 Children은 자주 함께 등장하고, Children은 여성과 더 자주 등장  
=> 모델이 여성에 대해 “Cooking” 을 예측할 가능성이 높아짐.



- Solution :

- Adversarial Debiasing 접근 방식
- 성별 단서를 직접적으로 제거하면서 가능한 한 많은  
작업 특정 정보를 보존



# Introduction

- Leakage(누설) :

## 1. Dataset Leakage : 정답라벨 -> 성별 맞추는 정도

- 예시 : "공구", "차고", "정비"라는 라벨이 있으면, 성별이 '남성'으로 판단

2. Model Leakage : 모델 결과 -> 성별을 맞추는 정도

- 예시 : 남자와 칼이 있는 사진

=> 칼만 보고 여자라고 판단

- $f(\text{Attacker})$  : Binary Classifier(male/female)
  - Alternative Data Splits :

$$\forall y : \frac{1}{\alpha} < \frac{\#(m, y)}{\#(w, y)} < \alpha$$

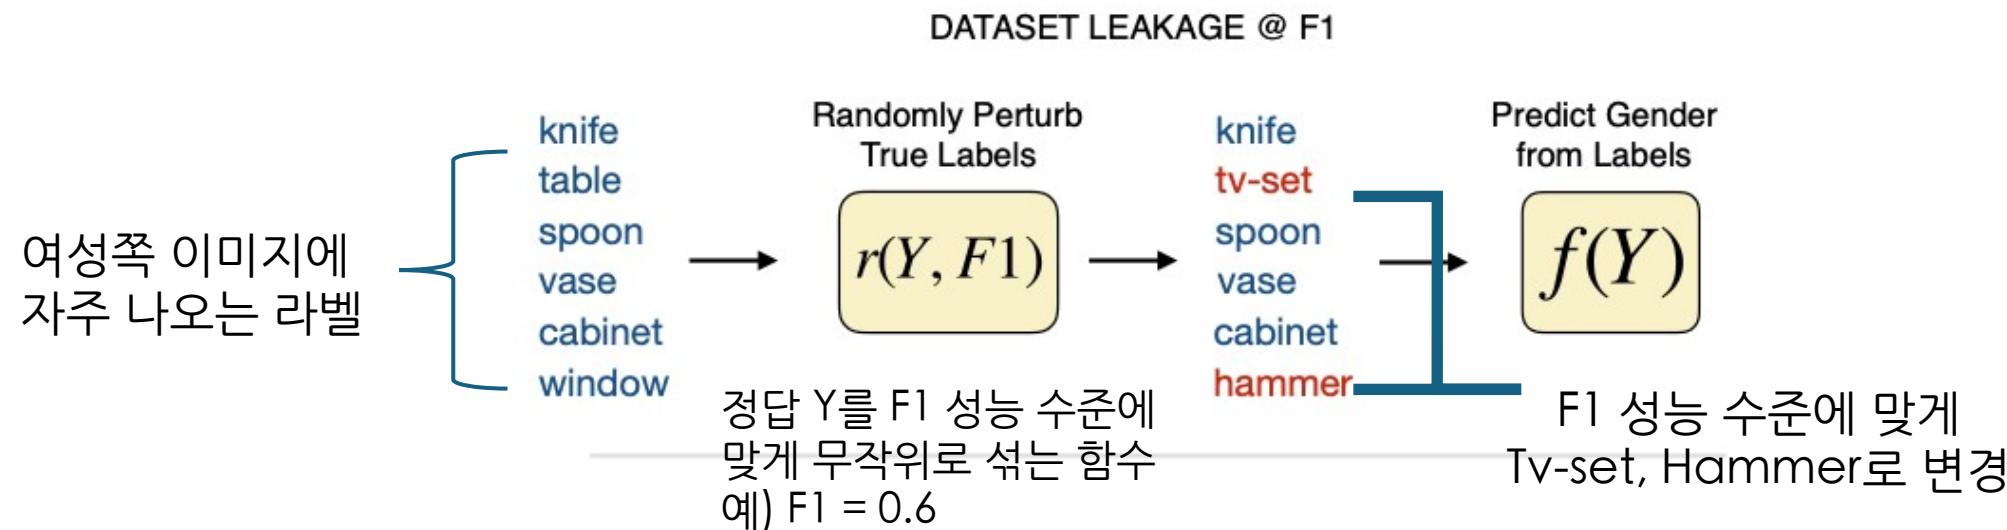
- $\#(m,y)$ : 라벨  $y$ 가 붙은 “남성” 이미지 수
- $\#(w,y)$ : 라벨  $y$ 가 붙은 “여성” 이미지 수
- $o \in \{3,2,1\}$ : 비율 협용 폴



# Introduction

F1 = 정밀도(Precision)와 재현율(Recall)의 조화평균

Precision(정밀도)과 Recall(재현율) 사이의 균형을 공정하게 반영하기 위해서  
(작은 값의 영향을 크게 받음)

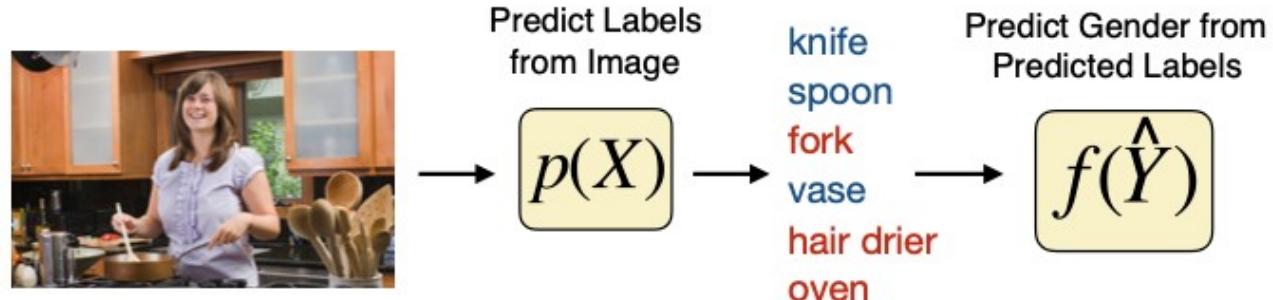


- 이미지의 라벨만 보고도 민감 속성(여기선 성별)을 예측할 수 있는 정도
- Task 목적 : 객체인식 -> 라벨만 보고 성별을 맞추면 문제 존재

# Introduction

---

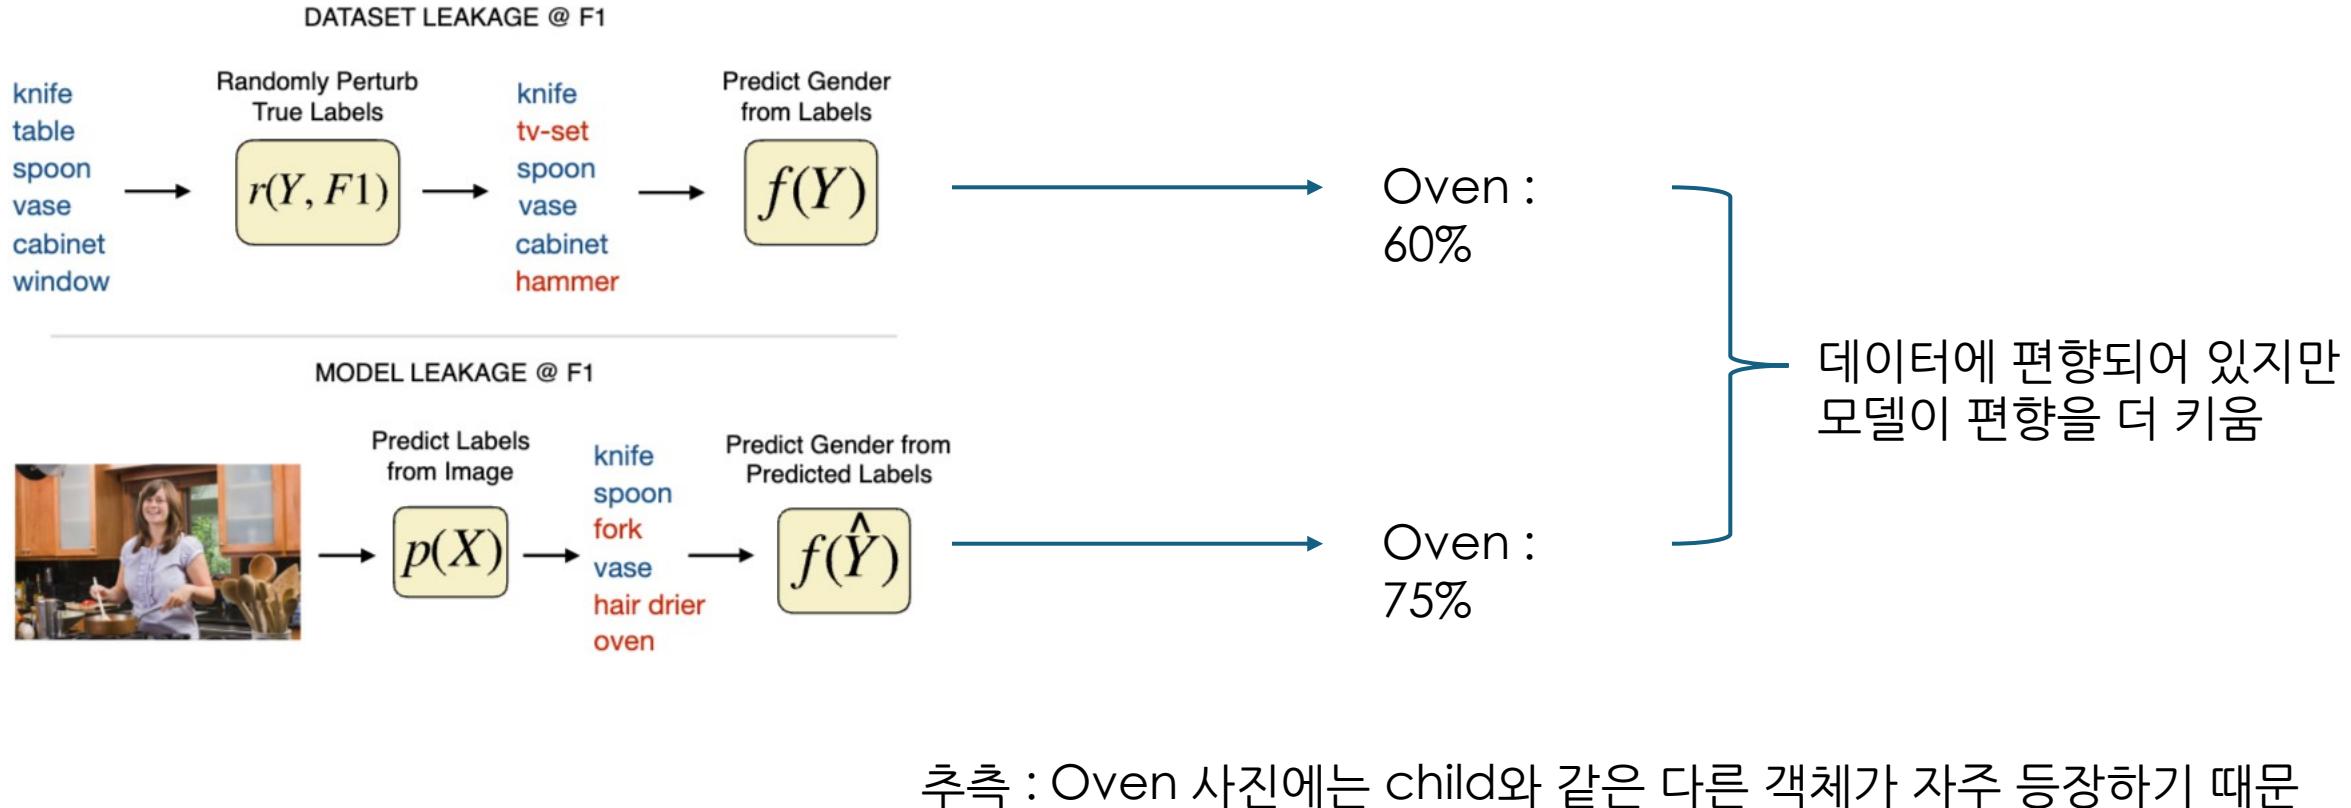
## MODEL LEAKAGE @ F1



1. image -> model -> label
2. 레이블을 보고 f가 남자인지 여자인지 판단함

원래 모델이 성별을 직접 예측하지 않았더라도, 출력된 라벨 패턴에서 성별 정보가 "누설(leakage)"될 수 있는지 측정

# Introduction

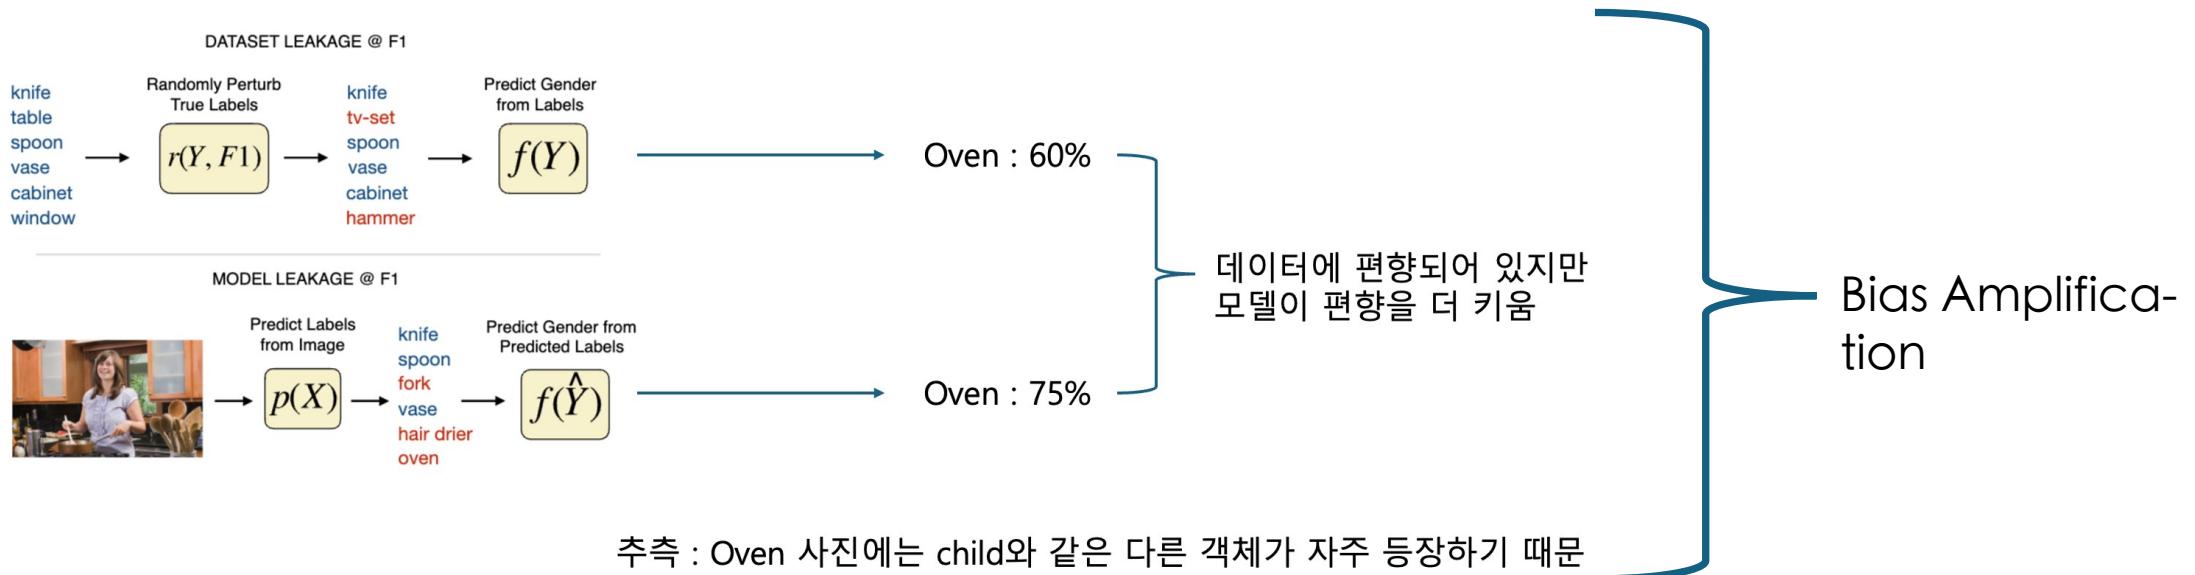


# Introduction

## ● Amplification(증폭) : Model Leakage-Dataset Leakage

- 모델이 데이터셋 편향보다 더 많은 성별정보를 증폭해서 노출하는 정도
- Delta값이 높을 수록 성별과 관련 된 정보를 활용해서 예측한다는 뜻(0이면 비편향)

$$\Delta = \lambda_M(a) - \lambda_D(a)$$



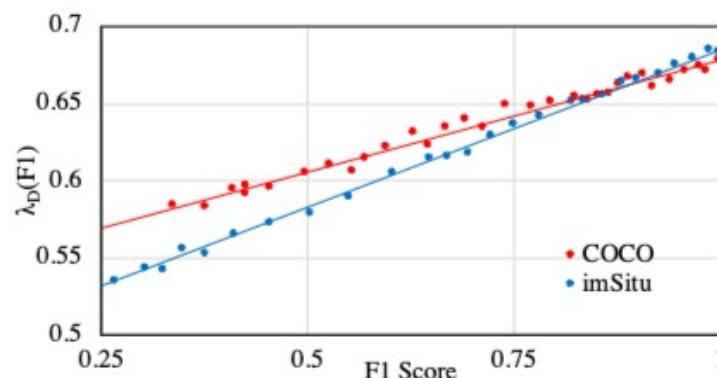
# Introduction

## ● Data Splits(Leakage, Performance)

CRF는 label 간 관계를 반영(객체와 성별 함께 예측, 결합확률을 높임)

dataset	split	Statistics		Leakage			Performance		
		#men	#women	$\lambda_D$	$\lambda_M(F1)$	$\lambda_D(F1)$	$\Delta$	mAP	F1
COCO [16] 객체	original CRF	16,225	6,601	$67.72 \pm 0.31$	$73.20 \pm 0.59$	60.35	12.85	57.77	52.52
	no gender	16,225	6,601	$67.72 \pm 0.31$	$70.46 \pm 0.36$	60.53	9.93	58.23	53.75
	( $\alpha = 3$ )	10,876	6,598	$62.00 \pm 0.98$	$67.78 \pm 0.29$	57.50	10.28	57.04	52.60
	( $\alpha = 2$ )	8,885	6,588	$56.77 \pm 1.45$	$64.45 \pm 0.56$	54.72	9.73	56.21	51.95
	( $\alpha = 1$ )	3,078	3,078	$53.15 \pm 1.10$	$63.22 \pm 1.11$	52.85	10.37	48.23	42.89
imSitu [36] 행동	original CRF	14,199	10,102	$68.26 \pm 0.31$	$78.43 \pm 0.26$	56.58	21.85	41.83	40.75
	no gender	14,199	10,102	$68.26 \pm 0.31$	$76.93 \pm 0.20$	56.46	20.47	41.02	40.11
	( $\alpha = 3$ )	11,613	9,530	$68.11 \pm 0.55$	$75.79 \pm 0.49$	55.98	19.81	39.20	37.64
	( $\alpha = 2$ )	10,265	8,884	$68.15 \pm 0.32$	$75.46 \pm 0.32$	55.74	19.72	37.53	36.41
	( $\alpha = 1$ )	7,342	7,342	$53.99 \pm 0.69$	$74.83 \pm 0.34$	53.20	21.63	34.63	33.94

dataset



# Method

- Adversarial Debiasing Model:

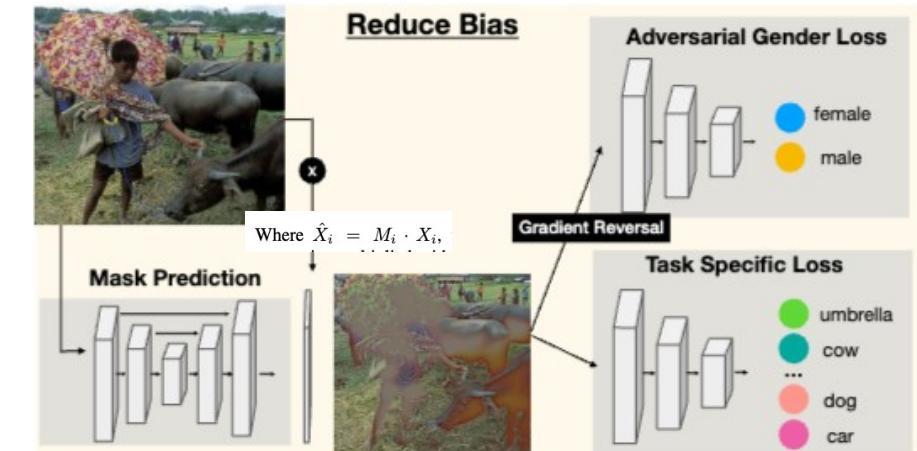
- Adv @ image : 이미지에서 직접 성별정보 제거.

U-Net 이용해서 마스크  $M_i$ 를 예측하기위해 encoder-decoder로 사용

- Gender Branch(ResNet-18) : 성별 예측

- 성별 예측자(Adversary)

- Main Branch(ResNet-50) : 타겟 분류(행동예측)



# Method

---

- Adversarial Debiasing Model:
  - Adv @ image
  - Adv @ conv 4
    - Resnet-50의 4번째 conv block에서 성별정보 제거
  - Adv @ conv 5
    - Resnet-50의 마지막 Conv Layer에서 성별정보를 제거
- 초기층은 필수 저수준 특징이 많아 성능 손실이 큅니다.
- 마지막층(conv5)은 고수준 성별 단서가 모여 정밀 제거가 유리

# Method

---

- Adversarial Debiasing Model:

$$L_p = \sum_i \left[ \underbrace{\beta \|X_i - \hat{X}_i\|_1}_{\text{① 원본 보존 항}} + \underbrace{L(p(\hat{X}_i), Y_i)}_{\text{② 주과제 손실}} - \underbrace{\lambda L_c(c(\hat{X}_i), g_i)}_{\text{③ 적대(성별 교란) 손실}} \right]$$

## 1. 원본 보존항 :

- 마스크를 쓰울 때 필요 이상으로 바꾸지 못하게
- L1 값이 크면 원본과 차이도 크다
- B값이 크면 원본 보존을 더 강하게 요구

## 2. Main Branch

- 가려진 이미지  $\hat{X}$ 도 정답을 잘 맞추도록

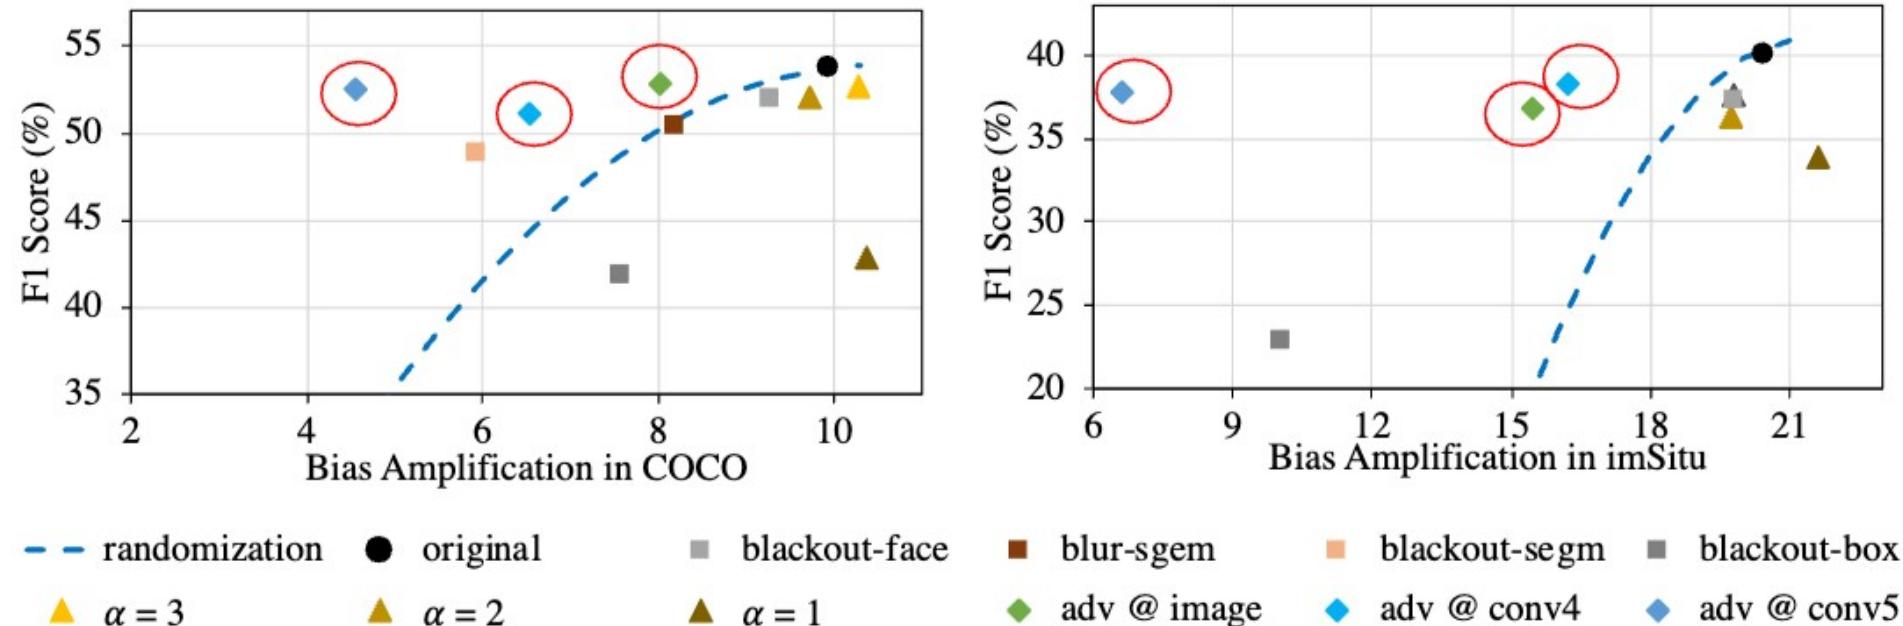
## 3. Gender(Adversary) Branch

- C(비평가)가 틀리게 유도
- Gamma가 크면 성별 단서를 더 숨김
- 성별을 못맞추게 하는 것이 목표

# Experiments

- Bias amplification vs F1

- Dataset : COCO(객체), imSitu(행동)
- Alpha : 성별간 라벨 동시 출현 비율
  - $\alpha = 1$  : 균형, 동시 출현 비율 동일( $\alpha=n$ 배 ; 여성n : 남성1)



# Experiments

---

	Leakage		Performance		
	$\lambda_M$ (F1)	$\lambda_D$ (F1)	$\Delta$	mAP	F1
original	70.46	60.53	9.93	<b>58.23</b>	<b>53.75</b>
blackout-face	69.53	60.24	9.29	55.93	51.81
blur-segm	68.19	59.99	8.20	55.06	50.26
blackout-segm	65.72	59.76	5.96	53.78	48.72
blackout-box	64.00	58.71	5.29	47.42	41.81
adv @ image	68.49	60.47	8.02	56.14	52.82
adv @ conv4	66.66	60.12	6.54	55.18	51.08
adv @ conv5	64.92	60.35	<b>4.57</b>	56.35	52.54
$(\alpha = 1)$	63.22	52.85	10.37	48.23	42.89
adv @ conv5	<b>54.91</b>	52.40	<b>2.51</b>	43.71	38.98

Adv @ conv5방식이 편향을 가장 많이 줄임

a=1로 만든 데이터셋에서 성능이 떨어지는 이유는 데이터 양과 다양성이 크게 줄어들었기 때문입니다

# Conclusion

---

- 데이터셋 누출(dataset leakage) · 모델누출(model leakage)을 정의하고, 둘의 차이( $\Delta$ )로 성별 편향증폭을 정량화
- 성별 라벨을 예측하지 않아도, 라벨-성별 동시출현을 ‘완전 균형’으로 맞춰도, 모델은 여전히 성별 편향을 증폭
- 원인: 어린이 · 의복 등 라벨되지 않은 성별-상관 단서가 중간표현에 남아 예측에 활용되기 때문입니다.
- 해결: 중간표현에 성별 판별자를 불인 적대적 학습(gradient reversal)으로 단서를 제거
- “균형 데이터만으로 부족” → 누출 측정으로 진단하고, 표현 수준의 편향 완화(적대적 학습 등)를 결합해야 공정성과 정확도의 균형을 달성합니다.